

阶段 4 的 Decoder-only causal LM (18.1M 参数)

token 序列

$t_1, t_2, \dots, t_n$

Token Embedding +
Position Embedding
(词表 16384×512)

Token Embedding 与 LM Head 共享权重

Transformer Layer $\times 3$

LayerNorm 1

Multi-Head Attention (8 heads)

QKV + 因果掩码 + 残差

LayerNorm 2

FFN: GELU($512 \rightarrow 2048 \rightarrow 512$)

+ 残差

因果掩码: 位置 i 只能
attend 到位置 $\leq i$

LayerNorm

LM Head (与 Embedding 共享, 16384 类)

logits $\rightarrow$ softmax $\rightarrow$ 预测下一个 token